



Tarea 2: Deep RL (2026-S1)

Problema 1: Conducción autónoma de vehículos (2 puntos)

Debido a sus sobresalientes conocimientos en aprendizaje reforzado, usted ha sido contactado por los ingenieros de Waymo, quienes enfrentan un problema crítico en sus sistemas de conducción autónoma.

Si bien sus vehículos han logrado un desempeño notable en condiciones controladas, aún presentan dificultades para tomar decisiones seguras y eficientes en escenarios dinámicos de autopista, donde múltiples vehículos interactúan simultáneamente, generando situaciones de alta incertidumbre.

Con el objetivo de mejorar sus algoritmos, Waymo le ha proporcionado acceso al simulador highway-env, el cual permite modelar distintos escenarios de conducción en autopistas, incluyendo cambios de pista, adelantos y cambios de velocidad.

Su tarea será entrenar un agente utilizando aprendizaje reforzado capaz de conducir un vehículo de manera autónoma en este entorno. En particular, se busca que el agente:

- Mantenga una conducción segura, evitando colisiones con otros vehículos.
- Maximice su eficiencia, avanzando lo más rápido posible dentro de límites razonables.
- Tome decisiones inteligentes de cambio de pista, considerando el comportamiento del resto del tráfico.
- Para minimizar costos, debe ser capaz de hacer todo esto utilizando únicamente un Lidar.

Su Tarea

- a) Utilizando los archivos `highway.py` y `DQN.py`, implemente un controlador basado en Deep Q-Networks (DQN) para obtener un comportamiento aceptable de conducción autónoma en el entorno.

Considere que el vehículo ya cuenta con un controlador de bajo nivel encargado del manejo de las ruedas directamente. Por lo tanto, el agente de RL debe actuar como un controlador de alto nivel que entrega comandos discretos al controlador de bajo nivel.

En particular, el espacio de acciones del agente está compuesto por cinco acciones:

- 0: Cambiar a la pista izquierda.
- 1: Mantener la pista y velocidad actual.
- 2: Cambiar a la pista derecha.
- 3: Aumentar la velocidad.
- 4: Disminuir la velocidad.

Entrene su agente DQN hasta obtener una política capaz de conducir de manera razonable, evitando colisiones y manteniendo un avance eficiente por la autopista. Usted podrá modificar los términos del reward para cumplir con su objetivo. Además, explique los hiperparámetros escogidos y presente los siguientes resultados:

- Curva de reward acumulado por episodio durante el entrenamiento.
- Evolución de la pérdida de entrenamiento de la red Q.
- Porcentaje de episodios terminados por colisión.
- Evaluación final del controlador entrenado.

b) A partir de su implementación base de DQN, incorpore y explique las tres mejoras estudiadas en clases:

- Double DQN
- Dueling DQN
- Prioritized Experience Replay (PER)

Para cada una de estas mejoras, describa brevemente la modificación realizada respecto a DQN estándar, explicando qué problema busca resolver y cómo impacta el proceso de aprendizaje. Posteriormente, implemente también una versión que combine las tres mejoras anteriores en un único agente. Reporte y compare:

- Curvas de reward acumulado durante el entrenamiento.
- Métricas de desempeño final (reward promedio, tasa de colisiones, duración de episodios).
- Velocidad de convergencia.

Finalmente, compare los resultados obtenidos y discuta:

- Qué mejoras generan el mayor impacto en el desempeño.
- Si los efectos observados coinciden con lo esperado teóricamente.

c) **BONUS (5 décimas):** Compare los valores de acción $Q(s, a)$ estimados por DQN y Double DQN para un conjunto representativo de estados del entorno.

Para ello, seleccione manualmente distintos estados y compare los valores de ambas redes para distintos puntos (épocas) de entrenamiento. Grafique la evolución de los valores de los estados y discuta:

- Si existe evidencia de sobreestimación en DQN en comparación con Double DQN.
- Cómo difieren las decisiones inducidas por ambos métodos a partir de sus estimaciones.
- Si Double DQN presenta valores más consistentes o estables.

Problema 2: Dynamic Wireless Power Transfer (2 puntos)

Gracias al rotundo éxito de Open Brain, Alan Brito ha decidido darse un gusto y ha adquirido su nuevo vehículo eléctrico de última generación: el Edison 3.0. Sin embargo, hay un pequeño problema; Alan Brito es extremadamente impaciente y no está dispuesto a perder tiempo esperando a que su vehículo se cargue de manera convencional.

Para esto, le ha pedido implementar un sistema de carga inalámbrica en movimiento basado en la tecnología conocida como *Dynamic Wireless Power Transfer* (DWPT).

El concepto de DWPT consiste en transferir energía eléctrica de manera inalámbrica desde la calle hacia el vehículo mientras este se encuentra en movimiento. Para ello, se instalan múltiples bobinas bajo la superficie del camino (bobinas primarias), las cuales se activan selectivamente para inducir corriente en una bobina secundaria ubicada en el vehículo (ver figura 1). De esta forma, el automóvil puede recargar su batería de manera continua sin necesidad de detenerse. Sin embargo, este sistema presenta desafíos importantes. Activar todas las bobinas simultáneamente es altamente ineficiente, mientras que una activación insuficiente puede provocar que el vehículo no reciba energía suficiente.

Su tarea será diseñar un controlador inteligente para un sistema compuesto por dos bobinas primarias. En cada instante de tiempo, el controlador deberá determinar el grado de activación de cada bobina y la frecuencia de conmutación del inversor, con el objetivo de maximizar la potencia transferida hacia el vehículo mientras este se desplaza sobre las bobinas.




Figura 1: Concepto de DWPT y circuito equivalente

Su Tarea

a) Investigue acerca de DWPT y responda:

- Investigue **brevemente** acerca de algunas aplicaciones importantes de DWPT.
- Explique el rol de la frecuencia de conmutación del inversor en la transferencia de potencia. ¿Por qué resulta deseable operar en torno a la frecuencia de resonancia del circuito LC del primario?
- Analice cómo la presencia del vehículo (bobina secundaria) modifica las características del sistema. En particular, explique cómo la inductancia mutua altera la frecuencia de resonancia efectiva del circuito.
- Desde una perspectiva de control, analice en qué situaciones conviene activar cada bobina primaria. Considere la posición relativa del vehículo, el acoplamiento electromagnético y la eficiencia energética del sistema. ¿Qué tipo de estrategia esperaría que su controlador aplicara?

b) Utilizando el simulador entregado en `dwpt_r1.py`, considere un sistema compuesto por dos bobinas primarias. En este entorno, el agente cuenta con dos variables de control continuas:

- **Frecuencia del inversor:** Variable continua en el rango $[-1, 1]$ que representa un desplazamiento relativo (Δf) respecto a una frecuencia nominal del sistema.
- **Distribución de potencia entre bobinas (share):** Variable continua en el rango $[-1, 1]$ que determina un desplazamiento relativo ($\Delta share$) de cómo se reparte la potencia total entre ambas bobinas primarias. En particular:
 - `share = 0`: toda la potencia se asigna a la bobina 1,
 - `share = 1`: toda la potencia se asigna a la bobina 2,
 - valores intermedios distribuyen la potencia de manera proporcional entre ambas bobinas.

Seleccionando `system_knowledge='full'`, como se muestra en `p2_main.py`, obtenga todas las variables importantes del sistema (ver `dwpt_r1.py`, función `_get_state` para su descripción). Utilizando esta información genere y luego comente los siguientes gráficos:

- **Perfil de acoplamiento magnético:** grafique k_1 y k_2 en función de la posición del vehículo x . Interprete en qué regiones del recorrido conviene utilizar principalmente la bobina 1, la bobina 2 o una combinación de ambas. Esto puede realizarse como sigue: `k1, k2 = env.coupling_profile(pos)`
- **Potencia transferida vs. frecuencia de conmutación:** para distintos valores del coeficiente de acoplamiento k_1 (utilice `share=0`), grafique la potencia de salida P_{out} en función de la frecuencia del inversor. Analice cómo cambia la frecuencia óptima cuando varía el acoplamiento entre bobinas. Esto puede realizarse con: `sol = env.solve_network(f, k, 0.0, share=share)`
- **Eficiencia vs. frecuencia de conmutación:** para los mismos valores de k_1 , grafique la eficiencia η en función de la frecuencia.

- **Potencia transferida vs. desfase:** grafique P_{out} en función del desfase de corriente ($phase1_deg$). Identifique la zona de operación recomendada y explique por qué el desfase puede ser una variable útil para controlar indirectamente la operación cercana a resonancia.
 - **Potencia transferida vs. distribución de potencia entre bobinas:** para distintos pares de acoplamiento (k_1, k_2), grafique P_{out} en función de **share** (fijando la frecuencia). Interprete cómo debería repartirse la potencia cuando el vehículo se encuentra más cerca de una bobina, de la otra, o en una zona intermedia.
- c) Para el caso `system_knowledge='full'`, implemente y compare los algoritmos PPO y SAC para controlar el sistema DWPT. En este escenario, el agente puede utilizar todas las variables entregadas por el entorno mediante la función `step`, por lo que dispone de información completa del estado del sistema.
- El objetivo principal del controlador será maximizar la potencia transferida hacia el vehículo, es decir, maximizar `p_out`. Para ello, entrene ambos agentes bajo condiciones variables de operación (velocidad variable del vehículo y distintas cargas de batería) con `env.reset(variable=True)`. Durante el entrenamiento, reporte y compare PPO y SAC utilizando al menos las siguientes métricas:

- Retorno acumulado por episodio.
- Potencia transferida promedio por episodio.
- Potencia transferida máxima por episodio.

Una vez finalizado el entrenamiento, evalúe ambos controladores sin exploración y compárelos con el controlador oráculo entregado en `dwpt_rl.py`. Para al menos tres combinaciones distintas de velocidad del vehículo y carga equivalente de batería, grafique y analice en función del tiempo:

- Potencia instantánea transferida hacia la batería, `p_out`.
- Eficiencia del sistema, `eta`.
- Frecuencia de conmutación, `f_sw`.
- Distribución de potencia entre bobinas, `share`.
- Desfase de las corrientes primarias, `phase1_deg` y `phase2_deg`.

Discuta cuál algoritmo obtiene mejor desempeño y explique sus resultados considerando la naturaleza continua del espacio de acciones.

- d) Finalmente, considere el caso `system_knowledge='no_comm'`, el cual representa un escenario más realista. En este caso, el controlador solo tiene acceso a variables medibles desde el lado primario del sistema y a información estimada mediante sensores externos, como la posición y velocidad del vehículo. Sin embargo, no existe comunicación entre el vehículo y el circuito primario, por lo que no se pueden observar directamente variables eléctricas del circuito secundario.

Repita el ítem anterior (comparación de PPO, SAC y el oráculo) y diseñe una recompensa adecuada con las variables disponibles para maximizar la potencia transferida. Justifique el diseño de su recompensa y comente sus resultados.

Problema 3: Planificación de rutina de ejercicios (2 Puntos)

Tras un largo periodo de excesos, Alan Brito ha decidido finalmente hacer algo por su salud y comenzar a hacer ejercicio. Sin embargo, fiel a su estilo, no quiere simplemente entrenar, quiere optimizar su rendimiento atlético lo más rápido posible. Para ello, nuevamente ha recurrido a usted, aprovechando sus conocimientos en aprendizaje reforzado.

En este problema, usted deberá diseñar un controlador capaz de generar una rutina de entrenamiento personalizada para Alan Brito. El sistema estará basado en un modelo dinámico del cuerpo humano frente a estímulos de ejercicio, inspirado en este paper. En términos generales, el modelo describe cómo cada sesión de entrenamiento

puede producir simultáneamente adaptaciones positivas, asociadas a mejoras de condición física, y efectos negativos, asociados a fatiga acumulada.

El objetivo será encontrar una política de entrenamiento que indique qué rutina aplicar cada día, buscando mejorar el desempeño de Alan Brito de manera eficiente. En particular, la rutina deberá cumplir con los siguientes requisitos:

- Maximizar el performance de Alan Brito para un periodo de un año.
- No permitir que la intensidad varíe demasiado de día en día.
- No tener más de 5 workouts de alta intensidad ($w_t > 2.5$) en una semana, para no matar a Alan Brito.
- Contar con ejercicios de estilos variados durante la semana para no aburrirlo.

Para esto, se le ha entregado una base de datos de workouts llamada `rl_workouts_500.json` en donde podrán encontrar distintos workouts que cuentan con:

- **id**: Identificador del workout
- **description**: Descripción del workout en texto
- **intensity_score**: Intensidad del workout
- **type**: Tipo del workout (G: Gymnastics, W: WeightLifting, C: Cardio)

Además, se le ha entregado un simulador que permite modelar el progreso de distintos atletas con características físicas y capacidades de recuperación diferentes en función de la intensidad de los entrenamientos diarios. En este entorno, la acción de control corresponde a seleccionar diariamente un nivel de intensidad de entrenamiento $w_t \in [0, 3]$.

El agente no observa directamente las variables internas del modelo, como condición física o fatiga acumulada. En cambio, solo tiene acceso a señales medibles por un wearable:

- **día/365**: Progreso temporal del año normalizado.
- **resting_hr**: Frecuencia cardíaca en reposo del atleta.
- **SpO₂**: Saturación de oxígeno en sangre.
- **Benchmark Score**: Puntaje obtenido en una prueba periódica realizada cada 7 días para medir el desempeño.
- $w_{t-1}/w_{\text{máx}}$: Intensidad de entrenamiento aplicada el día anterior, normalizada.

Su Tarea

- Diseñe una función de recompensa para entrenar el agente, considerando los requisitos antes mencionados y considerando que durante el entrenamiento se permite utilizar la variable `env.true_performance`. Esta variable representa el desempeño real del atleta, aunque no forma parte de las observaciones disponibles para el agente. Explique claramente el flujo completo de su controlador. En particular, describa cómo el agente selecciona una intensidad w_t , cómo dicha intensidad se traduce en un workout específico desde `rl_workouts_500.json`, y cómo se calcula la recompensa utilizada para actualizar la política.
- Implemente los algoritmos DDPG y TD3 para resolver el problema anterior. Entrene ambos métodos bajo las mismas condiciones experimentales y compárelos en términos de:
 - Retorno acumulado por episodio.
 - Evolución del `true_performance` durante el año.
 - Intensidad promedio semanal.
 - Variedad semanal de workouts utilizados.
 - Suavidad de la política, medida por cambios diarios en la intensidad $|w_t - w_{t-1}|$.

Realice la comparación utilizando al menos tres perfiles distintos de atletas, modificando los parámetros `athletic_level`, `recovery_speed` y `fitness_retention`. Para cada perfil, grafique la intensidad aplicada a lo largo del tiempo y muestre segmentos representativos de semanas o meses indicando los tipos de workouts seleccionados.

- c) Modifique la función de recompensa considerando ahora un escenario más realista, en el cual no se tiene acceso a `env.true_performance`. Es decir, en este caso, la recompensa deberá construirse únicamente a partir de las señales observables entregadas por el wearable.

Justifique cómo estas señales pueden utilizarse como indicadores indirectos de mejora física, recuperación o fatiga acumulada.

Repita el entrenamiento y la comparación entre DDPG y TD3 utilizando los mismos tres perfiles de atletas del punto anterior. Reporte nuevamente las métricas y gráficos solicitados, y compare el desempeño obtenido con respecto al caso donde sí se utilizaba `env.true_performance` para diseñar la recompensa.

Finalmente, discuta qué tan robusta resulta la política aprendida cuando el controlador solo dispone de mediciones indirectas del estado físico del atleta.

Anexo

Informe

El informe debe ser realizado en Latex, utilizando el template que está en Canvas.

Código

- Todo su código debe ser realizado en python version ≥ 3.11 .
- Está estrictamente prohibido el uso de Chatbots para completar su tarea. Si el profesor o los ayudantes determinan que utilizó un chatbot durante el desarrollo la tarea se calificará con Nota 1 (Ver diapositivas de la primera clase para el detalle de los lineamientos del curso en este tema).